

Fundamentos de redes neuronales artificiales

Auto codificadores

Emiliano Damián Churruca

Laboratorio de Investigación y Desarrollo en
Computación(LIDEC)

Universidad Nacional de Hurlingham

(Material desarrollado por Juan Miguel Santos y adaptado
para este curso)

¿Qué es un auto codificador?

Introducción

- Un auto codificador es una red neuronal artificial que tiene una arquitectura de perceptron multicapa.
- Su arquitectura tiene como característica que la dimensión de la entrada d coincide con la dimensión de la salida.


¿Qué es un auto codificador?

Introducción

- La red tiene una o más capas ocultas, en número impar y de tal forma que se puede identificar una capa oculta en el medio denominada **capa latente**.
- Lo usual es que la capa latente tenga un número de unidades k , con $k < d$.

¿Qué es un auto codificador?

Esquema general de la arquitectura de un auto codificador



¿Qué es un auto codificador?

Aprendizaje

- Dado un conjunto de entrenamiento X

$$X = X^1, X^2, \dots, X^n$$

con n ejemplos y donde cada ejemplo $X^i, 0 < i \leq n$ tiene dimensión d tal que

$$X^i = (X_1^i, X_2^i, \dots, X_d^i),$$

el conjunto de salidas deseadas es definido como Y siguiendo:

$$Y = X.$$

- Esto es, la red debe aprender a representar en sus salidas lo mismo que recibe como entrada.

¿Qué es un auto codificador?

Aprendizaje

- ✚ Para esto, usa el algoritmo de retropropagación con una función de costo (o pérdida o Error, como gusten nombrarla) definida por

$$E = \frac{1}{2} \sum_{i=1}^n \sum_{l=1}^d (Y_l^i - O_l^i)^2.$$

- ✚ La función de activación de las unidades, tanto de la capa oculta como la de salida, puede ser tanto no lineal (sigmoidea, relu, tanh, etc) como lineal.

La capa latente

Interpretación

- Usualmente, la capa latente tiene una dimensión k menor que la de la capa de entrada d .
- Una vez que el perceptron multicapa aprendió, para cada ejemplo de entrenamiento X^i que se presente a la red, se podrá observar una representación en un espacio de dimensión k (**espacio latente**).
- Es decir, se obtuvo una compresión (probablemente con alguna pérdida) en la representación de los datos de entrada.

La capa latente

Interpretación

- Si la capa latente tiene $k = 2$ y presentamos a la red el conjunto de todos los ejemplos de entrenamiento (siempre, una vez que la red ya haya aprendido), podemos graficar el valor de salida que toman las unidades de la capa latente, (V_1, V_2) en R^2 .
- El gráfico obtenido será una proyección de los datos de entrada en el **espacio latente**.

Auto codificadores lineales

Introducción

- Sea x una variable aleatoria y sean $\{x^1, x^2, \dots, x^n\}$ una muestra de x , se puede obtener la media $\bar{x}$ como

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x^i.$$

- Podemos también calcular la varianza de x que es una medida de cuan lejos están de $\bar{x}$ los valores de la muestra:

$$\text{var}(x) = \frac{1}{n} \sum_{i=1}^n (x^i - \bar{x})^2.$$

Auto codificadores lineales

Introducción

- Supongamos que nuestra variable aleatoria x es multivariada, es decir, cada x^i de una muestra de x es representada por un vector de dimensión d ,
 $x^i = (x_1^i, x_2^i, \dots, x_d^i)$.
- Supongamos que nuestra muestra tiene n elementos. Así, los datos de la muestra pueden ser representados por una matriz de n filas $\times$ d columnas.

Auto codificadores lineales

Introducción

Matriz de datos X

$$\begin{bmatrix} x_1^1 & x_2^1 & \dots & x_d^1 \\ x_1^2 & x_2^2 & \dots & x_d^2 \\ \vdots & & & \\ x_1^n & x_2^n & \dots & x_d^n \end{bmatrix}$$

Auto codificadores lineales

Introducción

- ✦ Cuando tenemos que cada ejemplo x^i del conjunto de datos es en realidad una instancia de un conjunto de variables aleatorias

$$x_1^i, x_2^i, \dots, x_d^i$$

nos podemos preguntar si dichas variables aleatorias $x_1, x_2, \dots, x_d$ están relacionadas entre sí o no.

Auto codificadores lineales

Introducción

- ✚ Por ejemplo, si el conjunto de datos es la información acerca de diversas características de una muestra de personas, podríamos encontrar la edad, la altura, el peso, cantidad de horas de ejercicio semanales, consumo de alcohol, etc.
- ✚ Es probable, por ejemplo, que la altura y el peso estén relacionadas entre sí.

Auto codificadores lineales

Introducción

- Una forma de medir eso es la covarianza que se define según:

$$\text{covar}(x_i, x_j) = \frac{1}{n-1} \sum_{k=1}^n (x_i^k - \bar{x}_i)(x_j^k - \bar{x}_j)$$

- Si el valor de $\text{covar}(x_i, x_j)$ es cero o cercano a cero, nos indica que ambas variables no están relacionadas entre sí, o simplemente no están correlacionadas.
- Si, en cambio, este valor es positivo y alto, indica un alto grado de correlación positiva.
- Si, el valor es negativo y alto, tiene un alto grado de correlación negativa.

Auto codificadores lineales

Introducción

- De esta forma podemos calcular la $covar()$ entre todas las variables que intervienen en los ejemplos del conjunto de datos:

$covar(x_1, x_2), covar(x_1, x_3), \dots, covar(x_2, x_1),$
 $covar(x_2, x_2), covar(x_2, x_3), \dots$

y así hasta la $covar(x_d, x_d)$.

(recordar que cada ejemplo de nuestro conjunto de datos tiene dimensión d y por lo tanto está compuesto por d instancias de $x_1, x_2, \dots, x_d$).

Auto codificadores lineales

Introducción

- Los datos de *covar()* obtenidos los podemos organizar en una matriz llamada de covarianza:

$$\begin{bmatrix} s_{11} & s_{12} & \dots & s_{1d} \\ s_{21} & s_{22} & \dots & s_{2d} \\ \vdots & & & \\ s_{d1} & s_{d2} & \dots & s_{dd} \end{bmatrix}$$

donde escribimos s_{ij} para representar la $covar(x_i, x_j)$ por simplicidad.

Auto codificadores lineales

Introducción

- ✦ Si a cada variable x_i le restamos su media muestral y los dividimos por la desviación estándar (la raíz cuadrada de su varianza) obtenemos la **variable estandarizada**:

$$z_i^j = \frac{x_i^j - \bar{x}_i}{\sqrt{s_{ii}}}$$

entonces, la covarianza muestral entre z_i y z_k será la correlación muestral entre z_i y z_k y se nota como r_{ik} .

Auto codificadores lineales

Introducción

- Si estandarizamos cada una de las variables $x_1, \dots, x_d$ y luego calculamos la *covar()* obtendremos una matriz del estilo:

$$\begin{bmatrix} 1 & s_{12} & \dots & s_{1d} \\ s_{21} & 1 & \dots & s_{2d} \\ \vdots & & & \\ s_{d1} & s_{d2} & \dots & 1 \end{bmatrix}$$

Auto codificadores lineales


Introducción

- Fijarse que, s_{ii} es la varianza de la variable x_i y es igual a 1 que indica una correlación máxima y positiva.
- Un valor de 0 o cercano a 0 en algún s_{ij} indica que no hay correlación entre las variables x_i y x_j .
- Un valor de -1 o muy cercano a -1 indica una fuerte correlación negativa entre ambas.

Auto codificadores lineales

Introducción


Consideremos ahora un conjunto de datos donde cada ejemplo está representado por dos variables aleatorias:



Auto codificadores lineales

Introducción

Si consideramos en qué dirección la muestra tiene mayor variabilidad podemos trazar nuevos ejes:



Auto codificadores lineales

Introducción

- ✚ ¿Cómo encontrar esos ejes?
- ✚ La matriz de covarianza tiene la particularidad de ser simétrica y semidefinida positiva.
- ✚ Por lo tanto se puede factorizar de acuerdo a:

$$\frac{X^t X}{(n-1)} = E U E^t$$

donde E es una matriz cuyas columnas son autovectores y U es una matriz diagonal con los autovalores de cada uno de los autovectores.

Auto codificadores lineales

Introducción

- ✚ Nota: un autovector v con un autovalor asociado u de una matriz A satiface:

$$Av = vu$$

Fijarse que, como v es un vector columna, si expresamos todos los valores columna como una matriz E tenemos que:

$$AE = EU$$

de donde

$$A = EUE^{-1} = EUE^t$$

dado que E es una matriz ortogonal pues los vectores (autovectores) que la forman son ortogonales entre sí.

Auto codificadores lineales

Introducción

- ✚ Como principal conclusión tenemos que la matriz de covarianza se puede factorizar en
$$\frac{X^t X}{(n-1)} = E U E^t$$
y que las columnas de E son autovectores y U es una matriz diagonal con sus elementos los autovalores.
- ✚ ¿Porqué esto debería importarnos?

Auto codificadores lineales

Introducción

- ✧ Pues el autovector que tiene asociado el mayor autovalor corresponde a la dirección en que los datos tienen mayor variabilidad.
- ✧ El autovector asociado al segundo autovalor tiene la dirección en que los datos tienen la segunda mayor variabilidad, y así sucesivamente.

Auto codificadores lineales

Introducción

- ✚ De esto se vale el análisis de componentes principales (ACP o PCA de sus siglas en inglés).
- ✚ Sea X el conjunto de datos, y $X^1, X^2, \dots$ cada una de los ejemplos (filas) de la matriz X , si multiplicamos X^1 por el primer autovector obtendremos un valor escalar pc_1 que se llama primer componente principal.
- ✚ Si multiplicamos X^1 por el segundo autovector tenemos pc_2 que es la segunda componente principal, y así.

Auto codificadores lineales

Introducción

- Finalmente, tendremos
 $(pc_1, pc_2, \dots, pc_d)$
o sea, una nueva representación de del ejemplo X^1 .
- La parte interesante es que si tomamos las primeras componentes principales, por ejemplo, pc_1 y pc_2 estas expresarán la mayor variabilidad y podemos representar los datos con vectores de dimensión 2 en vez de expresarlos en dimensión d .

Auto codificadores lineales

Introducción

- ✦ Es decir, si proyectamos el espacio de entrada a través de la matriz de autovectores, obtendremos otra representación de la misma dimensión pero donde podemos tomar solamente las primeras componentes que explican el comportamiento de los datos.

Auto codificadores lineales

- ✦ ¿Qué relación tiene todo esto con los auto codificadores lineales?
- ✦ Sea X la matriz que representa el conjunto de datos de $n \times d$, es decir, n ejemplos, cada uno de dimensión d .
- ✦ Hay un tipo de descomposición denominada *DVS* (Descomposición en Valores Singulares) que permite expresar X de acuerdo a la siguiente factorización:

$$X = Z' S V^t$$

donde Z' es la matriz con columnas singulares izquierda, V es la matriz con columnas singulares derechas, y S es una matriz diagonal positiva.

Auto codificadores lineales

- ✚ Una característica de Z' y V^t es que son matrices ortonormales.
- ✚ El cálculo de $DVS(X)$ se realiza minimizando
$$||X - Z'SV^t||$$
- ✚ Pero si recordamos cómo funciona un perceptron multicapa que es la arquitectura que soporta un auto codificador, los pesos se obtienen minimizando:
$$||X - ZW^t||.$$

Auto codificadores lineales

- Supongamos que W sea ortonormal, entonces $X = ZW^t$ puede verse como

$$X = Z'SW^t$$

con $Z = Z'S$,

es decir, debiera existir matrices Z' y S tales que satisfagan $X = Z'SW^t$.

- Fijarse que, tanto para el auto codificador como para la descomposición en valores singulares, estamos minimizando $\|X - ZV^t\|$ y $\|X - Z'SV^t\|$ respectivamente.

Auto codificadores lineales

- ✦ Si reemplazamos a X en $\frac{X^t X}{(n-1)}$ por su descomposición en valores singulares

$$X = Z' S W^t$$

tenemos

$$\frac{X^t X}{(n-1)} = (Z' S W^t)^t (Z' S W^t) \frac{1}{(n-1)}$$

$$\frac{X^t X}{(n-1)} = (W^t)^t S^t Z'^t (Z' S W^t) \frac{1}{(n-1)}$$

$$\frac{X^t X}{(n-1)} = (W^t)^t S^t Z'^t Z' S W^t \frac{1}{(n-1)}$$

Auto codificadores lineales

✧ Como Z' es ortonormal, $Z'^t Z' = I$, entonces

$$\frac{X^t X}{(n-1)} = WS^t Z'^t Z' SW^t \frac{1}{(n-1)}$$

queda:

$$\frac{X^t X}{(n-1)} = WS^t SW^t \frac{1}{(n-1)}$$

y además, como S es diagonal, $S^t S = S^2$, y entonces:

$$\frac{X^t X}{(n-1)} = WS^2 W^t \frac{1}{(n-1)}$$

Auto codificadores lineales

Representación en la capa latente

✚ Resumiendo:

$$\frac{X^t X}{(n-1)} = W S^2 W^t \frac{1}{n-1}$$

✚ Pero, por ACP, si X es la matriz de datos,

$$\frac{X^t X}{n-1}$$

es la matriz de covarianza y siendo E la matriz de autovectores y U la matriz diagonal con los autovalores, entonces tenemos que:

$$E U E^t = \frac{X^t X}{(n-1)} = W S^2 W^t \frac{1}{n-1}$$

de donde

$$E = W \text{ y}$$

$$U = S^2 / (n - 1).$$

Auto codificadores lineales

Representación en la capa latente

- ✚ Nota: En el caso que W sea de $d \times d$, $W = E$.
Si W es de $d \times k$, con $k < d$,
se toman solo las k primeras columnas de E ,
con lo que E' quedaría de $d \times k$ y la igualdad es $W = E'$.
Analogamente con $W^t = E'^t$.

Auto codificadores lineales

Representación en la capa latente

- Usualmente, no se usa un autoencoder lineal para realizar el ACP de un conjunto de datos X .
- Sin embargo, si usamos funciones de activación no lineales (i.e. sigmoideas), podríamos interpretar al autoencoder como un ACP no lineal.
- En cualquier caso, obtendremos una representación en la capa latente de dimensión k , $k < d$.

Aplicaciones de los Auto codificadores

Eliminación de ruido

- Como el auto codificador aprende a reproducir en su salida la entrada que se le presenta, se puede enseñar al auto codificador a reproducir una salida sin ruido a partir de una entrada con ruido.
- Esto es, si $X' = N(\bar{X}, \sigma(X))$, en un eliminador de ruido debería ocurrir

$$x = \text{Decodificador}(\text{Codificador}(x'))$$

Aplicaciones de los Auto codificadores

Eliminación de ruido

- No necesariamente el ruido sobre las entradas tiene que ser gaussiano.
- Por ejemplo, se puede aplicar un tipo de ruido llamado *Sal y pimienta* que introduce, en una imagen, píxeles blancos y negros con una probabilidad.
- El ruido puede seguir diferentes tipos de distribuciones.
- El auto codificador que aprendió a reducir un tipo de ruido, en principio no es aplicable para un conjunto de datos que sigue una distribución diferente.

Aplicaciones de los Auto codificadores

Generación de nuevos ejemplos

- Sea X un conjunto de n datos de entrenamiento con dimensión d y sea Z el conjunto de las n representaciones de dimensión k de los ejemplos de X en la capa latente.
- Existen elementos z_i de Z que representan ejemplos que pertenecen a la misma distribución de X pero que no están en X .

Aplicaciones de los Auto codificadores

Generación de nuevos ejemplos

- ✚ Si aplicamos z_i al decodificador encontraremos, en la salida del auto codificador, a un ejemplo que sigue la misma distribución de X pero no está necesariamente en X .
- ✚ Si se quiere, y en términos mágicos, hemos generado un nuevo ejemplo del cual no disponíamos.

Aplicaciones de los Auto codificadores

Generación de nuevos ejemplos

- ✧ Por ejemplo, si X es un conjunto de imágenes con rostros de las personas, una vez entrenado el auto codificador, se puede ingresar al decodificador, un punto z_i del espacio latente que no sea ninguno de los que correspondan a los ejemplos de entrenamiento

$$z_i \notin Z = \text{Decodificador}(X).$$

- ✧ La expectativa es que aparezca el rostro de una persona que se parece a uno o a más de uno de los rostros usados para entrenar pero que no es igual a ninguno de ellos.

Aplicaciones de los Auto codificadores

Detección de datos atípicos

- ✦ Si se entrena a un autocodificador con un conjunto de datos X y luego se testea con otro conjunto T con la misma distribución, la expectativa es:

$$\|t'_1 - t_1\| < \epsilon$$

donde

$$t'_1 = \text{Decodificador}(\text{Codificador}(t_1)),$$

$t_1 \in T$ y T sigue la misma distribución de X .

Aplicaciones de los Auto codificadores

Detección de datos atípicos

- ✚ Sin embargo, si $t^* \in T$ y t^* es un dato atípico en T , entonces, no necesariamente

$$\|t'^* - t^*\| < \epsilon$$

donde

$$t'^* = \text{Decodificador}(\text{Codificador}(t^*)).$$